

1. Contexte et Présentation du Projet

Dans le cadre de la stratégie nationale d'amélioration du système éducatif marocain, le Ministère de l'Éducation Nationale souhaite mieux comprendre les facteurs qui influencent la réussite scolaire des élèves à l'échelle nationale.

Une mission d'analyse de données a été confiée à une équipe de Data Analysts avec pour objectif d'identifier les profils d'élèves à risque d'échec, d'évaluer l'impact des conditions socio-économiques et infrastructurelles sur les résultats académiques, et de formuler des recommandations concrètes pour orienter les décisions pédagogiques et budgétaires.

2. Problématique Métier

"Quels sont les facteurs scolaires, géographiques et socio-économiques qui influencent le plus la réussite académique des élèves au Maroc, et comment identifier en amont les élèves à risque d'échec scolaire ?"

Cette problématique s'articule autour de trois axes d'analyse :

- **Axe 1 — Performance individuelle** : Quels profils d'élèves réussissent le mieux ? Quel est l'impact de l'assiduité, des heures d'étude et de l'accès à internet ?
- **Axe 2 — Contexte établissement** : Les établissements privés surpassent-ils les publics ? Le milieu urbain/rural joue-t-il un rôle significatif ?
- **Axe 3 — Contexte régional** : Les inégalités régionales (pauvreté, alphabétisation, couverture internet) se reflètent-elles dans les taux de réussite ?

3. Objectifs Analytiques

#	Objectif	Type
1	Nettoyer et préparer les données issues des 3 sources	Technique
2	Explorer la structure et la qualité des données (EDA)	Analytique
3	Identifier les facteurs corrélés à la réussite scolaire	Analytique
4	Construire des KPIs pertinents par région, établissement et profil élève	Métier
5	Segmenter les élèves par niveau de risque d'échec	Analytique

6	Formuler des recommandations orientées décision	Métier
---	---	--------

4. Sources de Données

Dataset	Fichier	Description	Lignes	Colonnes
Élèves	students.csv	Données individuelles des élèves (notes, assiduité, profil)	~1 030	19
Établissements	schools.csv	Profil des établissements scolaires marocains	137	11
Stats régionales	regional_stats.csv	Indicateurs socio-économiques par région	8	9

Clés de jointure :

`students.school_id → schools.school_id`

`schools.region → regional_stats.region`

Origine des données :

Données synthétiques générées avec Python (pandas, numpy, random) dans le cadre d'un projet de formation Data Analyst. Conçues pour simuler le système éducatif marocain en s'inspirant de la structure des indicateurs publiés par le Ministère de l'Éducation Nationale (men.gov.ma) et le Haut-Commissariat au Plan (hcp.ma). Elles ne constituent pas des données officielles.

Limites : Absence de données longitudinales (une seule année scolaire 2023-2024).

5. Qualité des Données — Problèmes Identifiés

Problème	Colonnes concernées	Action attendue
Valeurs manquantes	math_score, attendance_pct, gender, french_score, parent_education, study_hours_per_day	Imputation ou suppression
Doublons	Toutes colonnes	Détection et suppression
Catégories incohérentes	gender, grade_level, status, internet_access	Normalisation
Valeurs aberrantes	math_score, age, study_hours_per_day, attendance_pct	Détection IQR / règles métier
Mauvais types	math_score, attendance_pct, age, average_score	Conversion et nettoyage

Formats de dates	enrollment_date	Standardisation YYYY-MM-DD
------------------	-----------------	----------------------------

6. KPIs à Construire

Performance académique

- Taux de réussite global (% Admis)
- Taux de réussite par région, par type d'établissement, par niveau
- Moyenne générale par matière
- Distribution des notes par décile

Assiduité et engagement

- Corrélation assiduité / moyenne générale
- Impact des heures d'étude quotidiennes sur les résultats
- Taux d'absentéisme par établissement

Facteurs socio-économiques

- Taux de réussite selon le niveau d'éducation des parents
- Impact de l'accès à internet sur la performance
- Comparaison urbain vs rural

Risque d'échec

- Profil type de l'élève à risque
- Score de risque composite (assiduité + notes + heures d'étude)

7. Pipeline de Traitement Attendu



8. Livrables Attendus

Livrable	Format	Description
Notebook de nettoyage	.ipynb	Pipeline documenté étape par étape
Notebook d'analyse	.ipynb	EDA, visualisations, KPIs
Dataset nettoyé	.csv	Données prêtes à l'analyse
Rapport / Présentation	.pdf ou .pptx	Synthèse des insights et recommandations

9. Technologies et Outils

Outil	Usage
Python (pandas, numpy)	Nettoyage et manipulation des données
Matplotlib / Seaborn / Plotly	Visualisation
Jupyter Notebook	Développement et documentation
Power BI / Tableau (optionnel)	Dashboard final

10. Recommandations Finales Attendues

Le projet doit aboutir à des recommandations concrètes adressées au Ministère de l'Éducation :

- Identification des régions et établissements prioritaires nécessitant un soutien
- Profil des élèves nécessitant un accompagnement pédagogique renforcé
- Impact mesurable de l'accès au numérique sur la performance
- Propositions d'allocation budgétaire basées sur les données